

# Sistema de Análise Dermatológica Automatizada em Pipeline: Um Protótipo de Aplicativo

Ronem Matos Lavareda Filho<sup>1</sup>, Matheus Saragoça de Lima<sup>1</sup>

<sup>1</sup>Instituto Federal de Educação, Ciência e Tecnologia do Amazonas (IFAM)  
Campus Parintins – Parintins, AM – Brasil

{ronem.lavareda, 2023325092}@ifam.edu.br

**Abstract.** *This work presents DermAI, an automated dermatological analysis system integrating AI models with mobile technology to improve healthcare accessibility in remote areas. The system unifies image classification, visual description, and clinical report generation through a cross-platform mobile app. Using computer vision and natural language processing, it enables automated skin lesion screening and structured medical reporting. Backend services support mobile interfaces, providing accessible tools for preliminary dermatological evaluation. Results confirm the feasibility of mobile-based AI screening, establishing a framework for early detection and healthcare access in underserved regions.*  
**Keywords:** Artificial Intelligence, Dermatology, Mobile Health, Computer Vision, Medical Diagnosis

**Resumo.** *Este trabalho apresenta o DermAI, sistema de análise dermatológica automatizada que integra IA e tecnologia móvel para ampliar a acessibilidade em saúde em regiões remotas. O sistema unifica classificação de imagens, descrição visual e geração de laudos clínicos em aplicativo multiplataforma. Utilizando visão computacional e processamento de linguagem natural, possibilita triagem automatizada de lesões cutâneas e relatórios estruturados. Serviços backend dão suporte às interfaces móveis, oferecendo ferramentas acessíveis para avaliação preliminar. Os resultados confirmam a viabilidade da triagem móvel baseada em IA, estabelecendo um framework para detecção precoce e acesso à saúde em áreas carentes.*  
**Palavras-chave:** Inteligência Artificial, Dermatologia, Saúde Móvel, Visão Computacional, Diagnóstico Médico

## 1. Introdução

O câncer de pele representa o tipo de neoplasia mais frequente no Brasil, correspondendo a cerca de 30% de todos os tumores malignos registrados no país, com estimativa de mais de 220.000 novos casos anuais [1]. Paradoxalmente, também possui uma das maiores taxas de cura quando detectado precocemente, atingindo índices superiores a 90% para melanomas identificados em estágio inicial [9]. Esta dualidade entre alta incidência e potencial curativo evidencia a importância crítica de sistemas eficazes de detecção precoce, especialmente em regiões com acesso limitado a cuidados especializados.

A região amazônica exemplifica de forma emblemática os desafios contemporâneos no acesso a cuidados dermatológicos especializados. Com apenas 0,5 dermatologistas por 100.000 habitantes — cinco vezes inferior à média nacional de 2,8 por 100.000 habitantes [3, 2] —, a região enfrenta um vazio assistencial crítico que resulta em tempos de espera

prolongados e diagnósticos tardios. Esta realidade é agravada pela extrema concentração geográfica dos poucos especialistas disponíveis: 93,1% dos médicos dermatologistas do Amazonas localizam-se na capital, Manaus, deixando 68% dos municípios do interior completamente desprovidos de serviços dermatológicos especializados [4].

O impacto desta carência transcende questões meramente logísticas, configurando-se como uma barreira estrutural ao direito constitucional à saúde. Deslocamentos para consultas especializadas podem custar até R\$ 80.000 em voos fretados [8], transformando o acesso médico em privilégio econômico. Consequentemente, doenças dermatológicas endêmicas como hanseníase, leishmaniose cutânea e casos de câncer de pele permanecem subdiagnosticados ou diagnosticados em estágios avançados, comprometendo significativamente o prognóstico dos pacientes.

Simultaneamente, observa-se na região uma infraestrutura digital emergente que oferece oportunidades inéditas para superação dessas barreiras. Dados recentes da Agência Nacional de Telecomunicações (ANATEL) indicam que 90% dos municípios da Amazônia Legal possuem cobertura de internet via satélite ou antenas [5], enquanto 84% da população adulta utilizam smartphones como principal meio de acesso digital [6]. A adesão integral dos municípios amazonenses a programas como o SUS Digital sinaliza um alinhamento político estratégico favorável à implementação de soluções de telemedicina [7].

Esta convergência entre necessidade médica urgente e disponibilidade tecnológica crescente cria uma janela de oportunidade histórica para soluções inovadoras de telediagnóstico. Recentes avanços em inteligência artificial, particularmente em modelos multimodais de visão computacional e processamento de linguagem natural, demonstram desempenho comparável a especialistas na análise de lesões cutâneas [10, 11]. A disponibilidade de frameworks de desenvolvimento móvel multiplataforma facilita a criação de interfaces acessíveis que podem democratizar o acesso a tecnologias médicas avançadas.

Neste contexto, este trabalho apresenta o DermAI, um sistema integrado que combina pipeline backend multimodal para análise dermatológica automatizada com aplicativo móvel multiplataforma. O sistema integra classificação automatizada de lesões cutâneas, descrição visual interpretável e geração de laudos clínicos estruturados em linguagem natural, proporcionando uma solução end-to-end para triagem dermatológica em dispositivos móveis. A arquitetura distribuída permite operação mesmo com conectividade intermitente, característica essencial para aplicação em regiões remotas da Amazônia.

A contribuição principal desta pesquisa reside na demonstração empírica de que a integração sinérgica de múltiplos modelos de IA especializados pode superar limitações de abordagens isoladas, resultando em sistema mais robusto e clinicamente útil. Diferentemente de soluções que focam exclusivamente em classificação de imagens, o DermAI oferece análise multimodal completa que inclui descrição morfológica detalhada e síntese de laudos médicos estruturados, características essenciais para aceitação clínica e tomada de decisão informada.

Os resultados apresentados confirmam a viabilidade técnica e clínica da abordagem proposta, estabelecendo um framework para detecção precoce e acesso à saúde em regiões com recursos limitados. O sistema demonstra aplicabilidade prática em cenários reais de uso, com tempo médio de processamento compatível com aplicações clínicas (28 segundos)

e compatibilidade multiplataforma que facilita a adoção.

## **2. Trabalhos Relacionados**

### **2.1. Aprendizado Profundo em Dermatologia**

A aplicação de aprendizado profundo em dermatologia evoluiu significativamente na última década. Esteva et al. [9] estabeleceram marcos fundamentais demonstrando que redes neurais convolucionais podem alcançar performance equivalente a dermatologistas experientes na classificação de lesões malignas e benignas. Trabalhos subsequentes de Haenssle et al. [22] e Brinker et al. [23] confirmaram o potencial superior de sistemas de IA em tarefas específicas de classificação dermatoscópica, estabelecendo bases sólidas para aplicação clínica.

### **2.2. Modelos Multimodais e Vision Transformers**

A transição de arquiteturas convolucionais para modelos baseados em atenção representa um avanço qualitativo. O Vision Transformer (ViT) introduziu mecanismos de auto atenção global para processamento de imagens [12], posteriormente refinado pelo Swin Transformer [10] através de janelas hierárquicas que reduzem a complexidade computacional de  $O(n^2)$  para  $O(n)$ .

Modelos multimodais de visão e linguagem constituem fronteira emergente para aplicações médicas interpretáveis. O BLIP-2 [11] e desenvolvimentos posteriores do LLaVA demonstram capacidades robustas na geração de descrições textuais clinicamente relevantes, combinando encoders visuais pré-treinados com modelos de linguagem de grande escala. Esta abordagem permite não apenas classificação visual, mas também explicação textual dos achados diagnósticos.

### **2.3. Desenvolvimento Móvel para Saúde Digital**

Na área de desenvolvimento móvel para saúde digital, React Native emergiu como framework dominante para aplicações multiplataforma [17], oferecendo vantagens significativas em termos de desenvolvimento e manutenção comparado a soluções nativas separadas. A integração entre APIs especializadas em processamento de IA médica e interfaces móveis responsivas representa tendência emergente para democratização de tecnologias avançadas de saúde, conforme demonstrado em trabalhos de referência na área de saúde digital [26].

### **2.4. Lacunas Identificadas na Literatura**

Apesar destes avanços, lacunas significativas persistem na literatura. Poucos trabalhos abordam integração completa de múltiplos modelos de IA para geração de laudos estruturados com interfaces móveis nativas. Adicionalmente, a maioria das pesquisas foca em datasets internacionais, negligenciando características epidemiológicas e fenotípicas específicas de populações brasileiras e os desafios únicos de implementação em regiões com recursos limitados, conforme destacado por Garnelo et al. [27] e Viana et al. [28].

## **3. Metodologia**

### **3.1. Arquitetura Geral do Sistema**

O DermAI implementa uma arquitetura distribuída cliente-servidor composta por dois componentes principais integrados: um pipeline backend multimodal para processamento

de IA e um cliente móvel multiplataforma para interface do usuário. Esta separação permite otimização independente dos componentes, escalabilidade horizontal e facilita a manutenção em ambientes de produção.

A Tabela 1 apresenta uma comparação entre diferentes abordagens arquiteturais consideradas durante o desenvolvimento:

**Tabela 1. Comparação quantitativa de arquiteturas para sistemas móveis de análise dermatológica**

Abordagem		Performance <sup>1</sup>	Escalabilidade <sup>2</sup>	Requisito de Conectividade <sup>3</sup>
Processamento Local		Excelente (>90%)	Limitada (<100 usuários)	Independente
Arquitetura Híbrida		Moderada (70-89%)	Moderada (100-1000 usuários)	Intermitente
Cliente-Servidor		Boa (80-95%)	Alta (>1000 usuários)	Contínua
Edge	Computing	Excelente (>90%)	Muito (>5000 usuários)	Alta Baixa

<sup>1</sup> Performance medida como taxa de sucesso no processamento de imagens

<sup>2</sup> Escalabilidade baseada no número de usuários simultâneos suportados

<sup>3</sup> Requisito de conectividade para funcionamento completo do sistema

### 3.2. Pipeline Backend Multimodal

O backend adota arquitetura modular baseada em Flask [18], organizando-se em camadas especializadas para diferentes aspectos do processamento multimodal, conforme detalhado na Tabela 2:

**Tabela 2. Camadas arquiteturais do pipeline backend**

Camada	Responsabilidade	Tecnologia	Latência (ms)
API	Interface REST	Flask 3.1.1	50-100
Validação	Pré-processamento	OpenCV, PIL	200-500
Classificação	Análise visual	hasibzunair/melanet	3000-5000
Descrição	Síntese textual	LLaVA	8000-12000
Laudos	Relatórios clínicos	Llama 3.1	15000-20000

**Estágio 1 - Validação e Pré-processamento:** Implementa verificação rigorosa de formato, dimensões e qualidade da imagem, seguida de aplicação de CLAHE (Contrast Limited Adaptive Histogram Equalization) [20] para melhoria de contraste local e normalização com estatísticas ImageNet padrão.

**Estágio 2 - Classificação:** Utilização do modelo hasibzunair/melanet [14] para classificação binária maligno/benigno de lesões cutâneas, selecionado após avaliação sistemática de múltiplos candidatos.

**Estágio 3 - Descrição Visual:** Emprego do LLaVA para geração de descrições objetivas das características morfológicas observadas, seguindo critérios dermatológicos estabelecidos na literatura médica especializada.

**Estágio 4 - Síntese de Laudos:** Utilização do Llama 3.1 [13] para geração de relatórios clínicos estruturados em português, integrando resultados dos estágios anteriores em formato padronizado para interpretação clínica.

A principal vantagem dessa estratégia consiste em sua elevada capacidade de adaptação, permitindo integrar os benefícios de diferentes abordagens. Além de ser facilmente atualizável e aplicável a distintos contextos, favorece a manutenção dos sistemas e contribui para um maior domínio e compreensão dos processos envolvidos.

### 3.3. Avaliação Comparativa de Modelos de IA

Durante o desenvolvimento foi conduzida avaliação sistemática de múltiplos modelos de inteligência artificial para cada componente da pipeline, considerando métricas de estabilidade operacional e adequação clínica para integração em sistemas móveis. A Tabela 3 sumariza os resultados desta análise:

Tabela 3. Avaliação comparativa de modelos de IA especializados				
Categoria	Modelo	Acurácia <sup>1</sup> (%)	Estabilidade Operacional <sup>2</sup>	
Classificação Visual	NeuronZero/ SkinCan-	55	Moderada (falhas: 15%)	
	cerClassifier			
	VRJBro/skin-cancer-detection	48	Baixa (falhas: 28%)	
	hasibzunair/melanet	81.18 <sup>3</sup>	Alta (falhas: < 3%)	
Descrição Visual	BLIP-2	N/A <sup>4</sup>	Baixa (alucinações: 35%)	
	LLaVA	N/A <sup>4</sup>	Alta (alucinações: < 8%)	
Síntese de Texto	Tiny Llama	N/A <sup>4</sup>	Baixa (inconsistente: 42%)	
	ChatGPT-3.5	N/A <sup>4</sup>	Moderada (limitações: 12%)	
	Llama 3.1	N/A <sup>4</sup>	Alta (consistente: > 95%)	

<sup>1</sup> Para modelos de classificação, medida em datasets de validação próprios dos autores

<sup>2</sup> Estabilidade medida durante testes de integração no sistema DermAI

<sup>3</sup> Resultado obtido do trabalho original de Zunair & Hamza (2020) no dataset ISIC-2016

<sup>4</sup> N/A indica a não aplicabilidade dessa métrica para modelos de geração de texto

#### 3.3.1. Modelos de Classificação

Inicialmente, o desenvolvimento focou em soluções multiclasse para detecção abrangente de lesões dermatológicas. No entanto, a avaliação sistemática revelou limitações significativas desta abordagem:

O modelo NeuronZero/SkinCancerClassifier [15], baseado em Swin Transformer, demonstrou acurácia limitada de 55% em testes de integração, comprometendo a viabilidade clínica devido ao desbalanceamento nas bases de treinamento. Similarmente, o modelo VRJBro/skin-cancer-detection [16] apresentou performance ainda mais limitada.

A mudança de detecção multiclasse para binária ocorreu pela baixa performance dos modelos multiclasse avaliados, que apresentaram acurácia limitada para uso clínico. A transição para um modelo binário (hasibzunair/melanet) se mostrou estratégica por resultar em um sistema mais robusto e com melhor desempenho, sendo mais adequado para a triagem primária. O modelo hasibzunair/melanet apresenta acurácia documentada de 81.18% (AUC) e sensibilidade de 91.76% na classificação binária maligno/benigno, conforme validação original realizada pelos autores no dataset ISIC-2016 com 379 imagens de teste [14].

### **3.3.2. Modelos de Análise Visual e Síntese**

Para descrição visual, o LLaVA emergiu como alternativa superior ao BLIP-2 [11], demonstrando melhor desempenho na geração de descrições objetivas e menor incidência de conteúdo alucinatório em contextos médicos especializados durante os testes de integração.

Para síntese de laudos, o Llama 3.1 [13] foi selecionado após demonstrar equilíbrio otimizado entre qualidade de síntese e estabilidade operacional, superando alternativas como Tiny Llama e ChatGPT-3.5 em consistência de geração de conteúdo médico estruturado.

## **3.4. Cliente Móvel Multiplataforma**

O cliente foi desenvolvido utilizando React Native [17] com Expo SDK [19], garantindo compatibilidade multiplataforma nativa para Android, iOS e navegadores web. A arquitetura prioriza integração eficiente com a API backend, monitoramento de conectividade em tempo real e experiência do usuário adaptativa.

### **3.4.1. Design da Interface do Usuário**

A interface do DermAI foi projetada seguindo princípios de usabilidade médica e acessibilidade, implementando design responsivo que se adapta a diferentes tamanhos de tela e orientações. O sistema de navegação utiliza abordagem tab-based intuitiva, facilitando acesso rápido às funcionalidades principais.

A Tabela 4 detalha os componentes principais da interface e suas funcionalidades:

### **3.4.2. Interface Adaptativa e Responsiva**

O sistema implementa temas adaptativos que detectam automaticamente preferências do sistema operacional (modo claro/escuro), otimizando legibilidade em diferentes condições de iluminação. A interface responde dinamicamente ao status de conectividade, alternando entre modo online e offline com feedback visual adequado.

**Tabela 4. Componentes principais da interface do usuário**

Componente	Funcionalidade	Estado Offline
Botão Captura	Acesso à câmera nativa	Disponível
Seletor Galeria	Importação de imagens	Disponível
Indicador Status	Conectividade API	Tempo real
Barra Progresso	Etapas de processamento	Dinâmica
Visualizador Laudo	Resultados estruturados	Cache local
Botão Compartilhar	Export de resultados	Disponível
Menu Configurações	Preferências do usuário	Disponível

### 3.4.3. Integração API e Conectividade

A Tabela 5 detalha os endpoints de integração implementados:

**Tabela 5. Endpoints de integração API-Cliente**

Endpoint	Método	Propósito	Timeout (s)
/api/health	GET	Verificação de status	5
/api/predict	POST	Análise completa	60
/api/system	GET	Métricas do sistema	10
/api/models/status	GET	Status dos modelos	15

A integração foi projetada com foco em robustez e tolerância a falhas, garantindo que o cliente possa detectar indisponibilidades rapidamente por meio do endpoint de health check, ao mesmo tempo em que permite análises completas e consultas de métricas em tempo real.

### 3.4.4. Processamento e Captura de Imagens

A aplicação implementa captura direta via câmera e importação de galeria com pré-processamento automático otimizado para análise dermatológica. O sistema aplica redimensionamento inteligente, compressão adaptativa e validação de qualidade antes da transmissão para o backend, utilizando técnicas estabelecidas de processamento de imagens [21].

## 4. Implementação Técnica

### 4.1. Backend: Validação e Processamento Multimodal

O sistema implementa validação multicamada que verifica extensão, tipo MIME, dimensões (50x50 a 4096x4096 pixels) e integridade estrutural da imagem. O pré-processamento utiliza técnicas estabelecidas de melhoria de contraste através de CLAHE [20] aplicado no espaço de cor LAB, seguido de normalização e redimensionamento padronizado.

A Tabela 6 apresenta os parâmetros técnicos de cada estágio:

**Tabela 6. Parâmetros técnicos dos estágios de processamento**

Estágio	Resolução	Formato	Precisão
Input	Variável	JPEG/PNG	8-bit
CLAHE	224×224	RGB	8-bit
Classificação	224×224	Tensor	32-bit float
Descrição	Variável	RGB	8-bit
Output	Estruturado	JSON	-

## 4.2. API REST Estruturada

A API oferece endpoints especializados com documentação automática via Swagger, facilitando integração com diferentes tipos de clientes. O sistema implementa rate limiting, autenticação por tokens e logs estruturados para monitoramento em produção, seguindo padrões estabelecidos para aplicações web médicas [18].

## 4.3. Cliente Móvel: Integração e Experiência do Usuário

O cliente prioriza simplicidade de uso mantendo funcionalidade avançada. Os laudos gerados seguem estrutura padronizada incluindo diagnóstico preliminar, descrição morfológica, nível de confiança e recomendações de acompanhamento clínico. A interface permite compartilhamento direto dos resultados via sistemas de comunicação padrão do dispositivo.

A Tabela 7 sumariza as funcionalidades principais implementadas:

**Tabela 7. Funcionalidades do cliente móvel**

Funcionalidade	Descrição	Disponibilidade
Captura de Imagem	Câmera integrada	Online/Offline
Importação de Galeria	Seleção de arquivo	Online/Offline
Análise Automatizada	Processamento IA	Online
Visualização de Laudos	Interface estruturada	Online/Offline
Compartilhamento	Export de resultados	Online/Offline
Monitoramento API	Status em tempo real	Online
Cache Local	Armazenamento temporário	Offline

## 5. Experimentos e Resultados

### 5.1. Limitações Metodológicas e Riscos da Aplicação Médica Prematura

Este trabalho, desenvolvido no âmbito do Programa Institucional de Bolsas de Iniciação Científica Júnior, apresenta limitações metodológicas críticas e riscos potenciais que devem ser cuidadosamente considerados.

A **validação clínica insuficiente** representa uma limitação fundamental, pois a avaliação dos relatórios foi realizada por meio de critérios objetivos baseados na literatura médica, não contando com validação direta por especialistas em dermatologia. Esta limitação representa risco significativo, uma vez que falsos negativos podem retardar diagnósticos de lesões malignas, falsos positivos podem causar ansiedade desnecessária e



sobrecarregar o sistema de saúde, e a classificação binária (maligno/benigno) não captura a complexidade diagnóstica dermatológica.

Os **riscos de aplicação prematura** constituem outra preocupação crítica, visto que a implementação clínica sem validação adequada pode resultar em decisões médicas baseadas em análises não validadas, criar falsa sensação de segurança em casos que requerem atenção especializada, e potencialmente atrasar o acesso a cuidados médicos adequados em regiões remotas.

As **limitações de amostragem** também devem ser consideradas, pois os testes foram realizados com amostras limitadas e controladas, não representando a diversidade fenotípica da população brasileira, variações de qualidade de imagem em condições reais, nem diferentes tipos de lesões cutâneas prevalentes na região amazônica.

A diferença entre **ambiente controlado versus realidade clínica** apresenta desafios adicionais, já que os experimentos foram conduzidos em ambiente de desenvolvimento, não refletindo condições de iluminação variáveis durante captura de imagens, pressão temporal de decisões médicas, ou integração com fluxos de trabalho clínicos estabelecidos.

Por fim, as **considerações éticas e regulatórias** destacam que este trabalho não passou por aprovação de comitê de ética em pesquisa envolvendo aplicações médicas, avaliação regulatória para dispositivos médicos, nem análise de responsabilidade legal em caso de decisões incorretas.

**Recomendação de Uso:** O sistema deve ser considerado exclusivamente como prova de conceito técnico e ferramenta de apoio educacional, não devendo ser utilizado para decisões médicas reais sem validação clínica rigorosa por especialistas qualificados.

## 5.2. Metodologia Experimental

A validação do sistema DermAI foi conduzida através de avaliação sistemática focada na integração de componentes e performance operacional do sistema. Os experimentos realizados neste trabalho de PIBIC Jr concentraram-se em três categorias principais:

### 5.2.1. Testes de Performance e Latência

- **Objetivo:** Medir tempos de resposta e uso de recursos computacionais
- **Ferramentas:** Python 3.11 com bibliotecas `time`, `psutil`, `memory_profiler`
- **Hardware:** GPU RTX 2050 8GB VRAM, CPU Intel i5-12450H, 16GB RAM
- **Metodologia:** 100 execuções com imagens de diferentes tamanhos e qualidades
- **Métricas:** Tempo de processamento, consumo de memória, utilização de GPU

### 5.2.2. Testes de Conectividade e Robustez

- **Objetivo:** Avaliar comportamento do sistema em condições de rede variáveis
- **Ferramentas:** Python `requests`, `network-simulator`, `ping`
- **Cenários testados:** Conexões estáveis, intermitentes e offline
- **Métricas:** Taxa de sucesso de requisições, tempo de timeout, recuperação de falhas

### 5.2.3. Testes de Compatibilidade Multiplataforma

- **Objetivo:** Verificar funcionamento consistente entre plataformas
- **Ferramentas:** Expo CLI, React Native Debugger, Browser DevTools
- **Plataformas:** Android (API 21+), iOS (11+), navegadores web
- **Métricas:** Tempo de carregamento, consumo de memória, taxa de sucesso

O Pseudocodigo 1 apresenta um exemplo da metodologia utilizada nos testes de performance:

```
1 ALGORITMO TestarPerformanceSistema(imagem, iteracoes = 100)
2   resultados := {
3     tempos_processamento: [],
4     uso_memoria: [],
5     taxa_sucesso: 0
6   }
7
8   requisicoes_sucesso := 0
9
10  PARA i de 1 ATE iteracoes FACA
11    tempo_inicio := tempo_atual()
12    memoria_antes := memoria_usada()
13
14    TENTE
15      resposta := EnviarRequisicaoAnalise(imagem)
16      SE resposta.status = 200 ENTAO
17        requisicoes_sucesso := requisicoes_sucesso + 1
18      FIM SE
19    EXCECAO
20      CONTINUE
21    FIM TENTE
22
23    tempo_fim := tempo_atual()
24    memoria_depois := memoria_usada()
25
26    resultados.tempos_processamento.ADICIONAR(tempo_fim - tempo_inicio)
27    resultados.uso_memoria.ADICIONAR(memoria_depois - memoria_antes)
28  FIM PARA
29
30  resultados.taxa_sucesso := (requisicoes_sucesso / iteracoes) * 100
31  RETORNAR resultados
32 FIM ALGORITMO
```

**Listing 1. Pseudocodigo para testes de performance do sistema**

### 5.3. Performance de Classificação

O modelo hasibzunair/melanet [14], conforme documentado no trabalho original dos autores, apresenta as seguintes métricas de performance obtidas no dataset ISIC-2016:

- **Acurácia (AUC):** 81.18%
- **Sensibilidade:** 91.76%
- **Falsos Negativos:** 22 casos (redução de 50% comparado aos baselines)
- **Dataset de teste:** 379 imagens do ISIC-2016

Para este trabalho de PIBIC Jr, foram realizados testes de integração do modelo pré-treinado em condições simuladas de uso móvel, focando na estabilidade operacional e tempos de resposta em hardware consumer. A Tabela 8 apresenta os resultados dos testes de integração realizados:

**Tabela 8. Resultados dos testes de integração do modelo de classificação**

Métrica	Valor Médio	Desvio Padrão	Intervalo
Tempo de Classificação (s)	4.2	0.8	3.1 - 6.4
Uso de VRAM (MB)	1.847	156	1.620 - 2.100
Taxa de Sucesso (%)	97.2	2.1	95.0 - 100.0
Estabilidade Operacional	Alta	-	Falhas < 3%

## 5.4. Avaliação do Sistema Integrado

### 5.4.1. Performance Operacional

O sistema processa análises completas em tempo médio de 28 segundos em hardware padrão (GPU RTX 2050 8GB VRAM, CPU Intel i5-12450H, 16GB RAM), distribuído conforme apresentado na Tabela 9:

**Tabela 9. Distribuição temporal do processamento multimodal**

Componente	Tempo Médio (s)	Percentual (%)
Validação e Pré-processamento	2.1	7.5
Classificação hasibzunair/melanet	4.2	15.0
Descrição LLaVA	9.8	35.0
Síntese Llama 3.1	11.2	40.0
Estruturação de Resposta	0.7	2.5
<b>Total</b>	<b>28.0</b>	<b>100.0</b>

A arquitetura suporta imagens de até 20MB sem degradação significativa de performance, acomodando fotografias de alta resolução capturadas por dispositivos móveis modernos. A distribuição do tempo de processamento evidencia que os maiores custos estão concentrados nas etapas de descrição visual e síntese textual, o que é esperado dado o uso de modelos multimodais de grande porte.

Esse tempo de resposta encontra-se dentro de limites aceitáveis para aplicações de suporte clínico remoto, onde a prioridade recai sobre a completude e confiabilidade da análise. A modularidade da arquitetura permite futura otimização de componentes específicos sem comprometer a integridade do pipeline.

### 5.4.2. Usabilidade e Compatibilidade

Testes de usabilidade realizados em diferentes dispositivos revelaram características operacionais favoráveis, conforme apresentado na Tabela 10:

Tabela 10. Métricas de usabilidade multiplataforma			
Métrica	Android	iOS	Web
Tempo de captura (s)	8.2	7.5	9.1
Taxa de sucesso (%)	96.5	97.8	94.2
Consumo de memória (MB)	245	198	312
Compatibilidade mínima	5.0	11.0	ES6

Os resultados demonstram boa consistência entre as plataformas, com tempos médios de captura estáveis e altas taxas de sucesso no carregamento e processamento das imagens. O consumo de memória variou conforme a arquitetura de cada sistema, mantendo-se dentro de limites aceitáveis para dispositivos móveis intermediários e navegadores modernos.

### 5.4.3. Qualidade dos Laudos Gerados

Foi realizada avaliação sistemática da qualidade de 50 laudos gerados pelo sistema, utilizando critérios estruturados de adequação clínica. A avaliação foi conduzida mediante checklist padronizado baseado na literatura médica especializada, considerando as limitações de um projeto PIBIC Jr sem acesso direto a especialistas médicos para validação. A Tabela 11 detalha os critérios avaliados:

Tabela 11. Avaliação sistemática da qualidade dos laudos médicos gerados pelo DermAI			
Critério de Avaliação	Viabilidade Clínica (%)	Metodologia de Avaliação <sup>1</sup>	
Estruturação formal	96	Conformidade com padrões médicos	
Terminologia médica	92	Validação por glossário especializado	
Coerência diagnóstica	88	Consistência com classificação do modelo	
Recomendações clínicas	94	Alinhamento com protocolos estabelecidos	
Clareza linguística	90	Análise de legibilidade e compreensão	
Média ponderada <sup>2</sup>	92	Avaliação de 50 laudos	

<sup>1</sup> Cada critério foi avaliado por metodologia específica baseada em literatura médica  
<sup>2</sup> Média ponderada considerando importância clínica relativa de cada critério  
 Amostra: 50 laudos gerados durante os testes de validação (julho-agosto 2024)

Complementarmente, foram avaliadas métricas automáticas de qualidade textual. A perplexidade média dos laudos foi de 19.2, indicando fluidez compatível com textos técnicos da área médica. A densidade lexical alcançou 51%, demonstrando riqueza vocabular

adequada.

### 5.5. Testes de Conectividade e Robustez

Os testes de conectividade foram realizados simulando diferentes cenários de rede comuns em regiões remotas. A Tabela 12 apresenta os resultados:

Tabela 12. Resultados dos testes de conectividade					
Cenário	Latência (ms)	Taxa (%)	Sucesso	Timeout (s)	Recuperação (s)
Conexão Estável	45	98.5		-	-
Conexão Lenta	180	92.1		8.2	15.4
Conexão Intermitente	320	78.6		12.8	28.7
Offline (Cache)	-	100.0 <sup>1</sup>		-	-

<sup>1</sup> Funcionalidades offline limitadas (visualização de laudos salvos)

## 6. Discussão

### 6.1. Vantagens da Arquitetura Integrada

A integração sinérgica de pipeline backend multimodal com cliente móvel multiplataforma oferece vantagens significativas sobre soluções isoladas. A combinação de classificação visual precisa, descrições textuais interpretáveis e laudos estruturados resulta em sistema mais abrangente e clinicamente útil, conforme demonstrado em estudos similares de aplicações médicas baseadas em IA [24, 25].

A arquitetura distribuída permite otimização independente dos componentes, facilitando atualizações sem reengenharia completa do sistema. O cliente multiplataforma reduz substancialmente custos de desenvolvimento e manutenção comparado a soluções nativas separadas para cada plataforma.

### 6.2. Contribuições

Este trabalho de iniciação científica júnior contribui para a área de saúde digital através de:

- Integração de Modelos:** Demonstração prática de como combinar diferentes modelos de IA especializados em um pipeline coeso.
- Interface Móvel:** Desenvolvimento de interface multiplataforma acessível para análise dermatológica.
- Avaliação de Performance:** Quantificação de métricas operacionais em hardware consumer típico.
- Framework Open Source:** Disponibilização da arquitetura para desenvolvimento colaborativo futuro.

### 6.3. Limitações e Desafios Identificados

**Dependência de Conectividade:** A arquitetura atual requer conexão estável para funcionalidade completa, limitando a aplicabilidade em regiões com infraestrutura precária. Implementação de processamento offline parcial representa oportunidade de melhoria futura.

**Escalabilidade Computacional:** Requisitos de processamento para múltiplos modelos de IA podem limitar deployment em dispositivos de baixa capacidade. Otimizações como quantização de modelos são necessárias para democratização completa.

**Validação Clínica:** O sistema funciona como ferramenta auxiliar de triagem, não substituindo avaliação médica especializada. Estudos clínicos multicêntricos com participação de dermatologistas são necessários para validação definitiva da eficácia diagnóstica.

**Limitações do PIBIC Jr:** A ausência de validação clínica direta por especialistas representa limitação importante, compensada parcialmente pela rigorosa avaliação baseada em critérios da literatura médica.

#### 6.4. Impacto Esperado e Potencial Transformador

O DermAI demonstra potencial significativo para democratização do acesso a análise dermatológica especializada. O sistema pode funcionar como primeira linha de triagem automatizada, identificando casos suspeitos que requerem atenção médica urgente.

A padronização de descrições morfológicas e laudos estruturados pode contribuir substancialmente para melhoria da comunicação interprofissional e facilitar estudos epidemiológicos regionais. O sistema estabelece precedentes para aplicação de tecnologias de IA multimodal em contextos de saúde pública, alinhando-se com diretrizes internacionais de saúde digital [26].

### 7. Trabalhos Futuros

Desenvolvimentos prioritários incluem validação clínica multicêntrica com dermatologistas experientes para estabelecimento de benchmarks comparativos e confirmação da eficácia diagnóstica em condições reais de uso. Expansão do dataset com imagens de pacientes brasileiros é fundamental para melhoria da representatividade populacional e performance em diferentes fototipos cutâneos prevalentes no país.

Implementação de quantização avançada de modelos e processamento offline parcial permitirá deployment em dispositivos com recursos mais limitados, ampliando significativamente a acessibilidade da solução. Integração com sistemas hospitalares via padrões HL7/FHIR facilitará a incorporação em fluxos de trabalho clínicos estabelecidos.

Desenvolvimento de funcionalidades de análise temporal através de comparação de imagens sequenciais pode fornecer insights valiosos sobre evolução de lesões suspeitas. Esta capacidade é particularmente relevante para monitoramento longitudinal em regiões com acesso limitado a consultas presenciais regulares.

Estudos futuros devem incluir:

- Validação clínica com dermatologistas certificados
- Testes em condições reais de campo na região amazônica
- Avaliação de impacto em indicadores de saúde pública
- Otimização de modelos para redução de requisitos computacionais
- Expansão para detecção multiclasse de diferentes tipos de lesões

### 8. Conclusão

Este trabalho apresenta o DermAI, um sistema integrado inovador que combina pipeline backend multimodal com aplicativo móvel multiplataforma para análise dermatológica

automatizada. Desenvolvido no âmbito do Programa de Iniciação Científica Júnior, o projeto demonstra a viabilidade técnica de soluções integradas para aplicações médicas móveis, estabelecendo contribuições importantes dentro das limitações inerentes ao nível de formação.

A integração sinérgica de modelos especializados de IA (hasibzunair/melanet, LLaVA, Llama 3.1) com interface móvel adaptativa resulta em solução end-to-end capaz de gerar laudos estruturados com performance operacional adequada para aplicações de triagem. O uso do modelo hasibzunair/melanet, com acurácia documentada de 81.18% e sensibilidade de 91.76% no dataset ISIC-2016, fornece base sólida para classificação binária maligno/benigno.

A avaliação sistemática de múltiplos modelos de IA revelou a importância fundamental de validação empírica rigorosa, conduzindo à seleção de componentes otimizados para aplicações clínicas práticas. A transição estratégica de classificação multiclasse para binária resultou em melhoria substancial de estabilidade operacional, demonstrando que simplicidade arquitetural pode ser preferível à complexidade quando robustez clínica é prioritária.

O cliente móvel multiplataforma desenvolvido em React Native com Expo SDK demonstra viabilidade técnica de soluções integradas, oferecendo interface adaptativa, monitoramento de conectividade em tempo real e experiência de usuário otimizada. A compatibilidade com Android (API 21+), iOS (11+) e navegadores web garante ampla acessibilidade.

O tempo médio de processamento de 28 segundos em hardware consumer (RTX 2050, Intel i5-12450H, 16GB RAM) e a qualidade consistente dos laudos gerados (92% de adequação nos critérios avaliados) validam o potencial do sistema para triagem automatizada em contextos de recursos limitados. Os testes de conectividade demonstraram robustez adequada para diferentes cenários de rede, essencial para aplicação em regiões remotas.

O impacto esperado transcende capacidades técnicas, oferecendo oportunidade de democratização do acesso a análise dermatológica especializada. Em regiões como a Amazônia, onde a disponibilidade de dermatologistas é criticamente baixa, o DermAI pode representar diferença significativa na detecção precoce de câncer de pele e melhoria dos indicadores de saúde pública regional.

As limitações identificadas, incluindo dependência de conectividade, ausência de validação clínica direta e amostragem restrita, são consistentes com o escopo de um projeto PIBIC Jr e orientam desenvolvimentos futuros. A transparência sobre essas limitações reforça o rigor científico e estabelece expectativas realistas sobre as contribuições alcançadas.

A disponibilização da arquitetura como sistema aberto promove desenvolvimento colaborativo e reprodutibilidade científica, estabelecendo fundamentos sólidos para avanços futuros em dermatologia automatizada. Este trabalho demonstra como a integração inteligente de diferentes tecnologias de IA multimodal com interfaces móveis modernas pode resultar em soluções funcionais e acessíveis, mesmo considerando as limitações de recursos e expertise de um projeto de iniciação científica júnior.

A contribuição metodológica principal reside na demonstração empírica, no nível de um PIBIC Jr, de que sistemas integrados multimodais podem oferecer funcionalidade clínica superior através da sinergia entre classificação visual automatizada, descrição textual interpretável e síntese de laudos estruturados. Esta abordagem estabelece precedente importante para desenvolvimento futuro de sistemas de IA médica que priorizem não apenas acurácia técnica, mas também interpretabilidade clínica e acessibilidade prática.

## 9. Agradecimentos

Os autores agradecem ao Instituto Federal do Amazonas (IFAM) pelo apoio institucional e infraestrutura computacional disponibilizada para desenvolvimento e validação do sistema. Reconhecemos as contribuições fundamentais das comunidades de desenvolvimento de software livre, particularmente Hugging Face, Expo, React Native, Ollama e Meta AI, pela disponibilização dos modelos e frameworks que tornaram este trabalho possível. Agradecimentos especiais aos orientadores e ao programa PIBIC Jr pela oportunidade de desenvolvimento científico e pelas contribuições que enriqueceram significativamente a qualidade metodológica desta pesquisa.

## Referências

- [1] Instituto Nacional de Câncer José Alencar Gomes da Silva. *Estimativa 2023: Incidência de câncer no Brasil*. Rio de Janeiro: INCA, 2023. 156p.
- [2] Conselho Federal de Medicina; Faculdade de Medicina da USP. *Demografia Médica no Brasil 2023*. São Paulo: CFM, 2023. 312p.
- [3] Silva, L. M. P., Dourado, I., and Brito, S. O. C. (2018). Análise da distribuição espacial de dermatologistas no Brasil: desafios para o acesso equitativo. *Cadernos de Saúde Pública*, 34(8):e00085217.
- [4] Conselho Federal de Medicina. *Amazonas tem 1,19 médico por mil habitantes*. Portal CFM, 2018. Disponível em: <https://portal.cfm.org.br/noticias/amazonas-tem-119-medico-por-mil-habitantes/>. Acesso em: 15 ago. 2024.
- [5] Agência Nacional de Telecomunicações. *Relatório de Conectividade da Amazônia Legal 2024*. Brasília: ANATEL, 2024.
- [6] Instituto Brasileiro de Geografia e Estatística. *Pesquisa Nacional por Amostra de Domicílios Contínua - Tecnologia da Informação e Comunicação 2024*. Rio de Janeiro: IBGE, 2024.
- [7] Secretaria de Estado de Saúde do Amazonas. *SES-AM é destaque no Ministério da Saúde pela adesão ao SUS Digital*. Manaus: SES-AM, 2024. Disponível em: <https://www.saude.am.gov.br/sus-digital/>. Acesso em: 10 ago. 2024.
- [8] Ministério da Saúde. *Governo Federal amplia telessaúde na Amazônia*. DATASUS, 2024. Disponível em: <https://datasus.saude.gov.br/telessaude-amazonia/>. Acesso em: 12 ago. 2024.
- [9] Esteva, A.; Kuprel, B.; Novoa, R. A.; Ko, J.; Swetter, S. M.; Blau, H. M.; Thrun, S. *Dermatologist-level classification of skin cancer with deep neural networks*. *Nature*, v. 542, n. 7639, p. 115-118, 2017.



- [10] Liu, Z.; Lin, Y.; Cao, Y.; Hu, H.; Wei, Y.; Zhang, Z.; Lin, S.; Guo, B. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. Proceedings of the IEEE/CVF International Conference on Computer Vision, p. 10012-10022, 2021.
- [11] Li, J.; Li, D.; Xiong, C.; Hoi, S. *BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models*. Proceedings of the 40th International Conference on Machine Learning, v. 202, p. 19730-19742, 2023.
- [12] Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; Uszkoreit, J.; Houlsby, N. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. International Conference on Learning Representations, 2021.
- [13] Touvron, H.; Martin, L.; Stone, K.; Albert, P.; Almahairi, A.; Babaei, Y.; Bashlykov, N.; et al. *Llama 2: Open Foundation and Fine-Tuned Chat Models*. arXiv preprint arXiv:2307.09288, 2023.
- [14] Zunair, H.; Hamza, A. B. *Melanoma Detection using Adversarial Training and Deep Transfer Learning*. Physics in Medicine & Biology, v. 65, n. 13, p. 135005, 2020.
- [15] NeuronZero. *SkinCancerClassifier: Swin Transformer for Multi-Class Skin Cancer Classification*. Hugging Face Model Hub, 2024. Disponível em: <https://huggingface.co/NeuronZero/SkinCancerClassifier>. Acesso em: 05 jul. 2024.
- [16] VRJBro. *Skin Cancer Detection using Deep Learning*. Hugging Face Model Hub, 2024. Disponível em: <https://huggingface.co/VRJBro/skin-cancer-detection>. Acesso em: 05 jul. 2024.
- [17] Meta Open Source. *React Native: Learn once, write anywhere*. Documentação Oficial, 2024. Disponível em: <https://reactnative.dev/docs/getting-started>. Acesso em: 01 jul. 2024.
- [18] Pallets Projects. *Flask: A lightweight WSGI web application framework*. Versão 3.1.1. Disponível em: <https://flask.palletsprojects.com/en/3.0.x/>. Acesso em: 01 jul. 2024.
- [19] Expo Team. *Expo SDK Documentation: Build and deploy React Native apps*. Versão 51. Disponível em: <https://docs.expo.dev/>. Acesso em: 01 jul. 2024.
- [20] Zuiderveld, K. *Contrast Limited Adaptive Histogram Equalization*. In: Graphics Gems IV. Academic Press Professional, p. 474-485, 1994.
- [21] Bradski, G.; Kaehler, A. *Learning OpenCV 4: Computer Vision and Machine Learning with the OpenCV Library*. 2<sup>a</sup> ed. O'Reilly Media, 2020.
- [22] Haenssle, H. A.; Fink, C.; Schneiderbauer, R.; Toberer, F.; Buhl, T.; Blum, A.; Kalloo, A.; et al. *Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists*. Annals of Oncology, v. 29, n. 8, p. 1836-1842, 2018.
- [23] Brinker, T. J.; Hekler, A.; Enk, A. H.; Klode, J.; Hauschild, A.; Berking, C.; Schilling, B.; et al. *Deep learning outperformed 136 of 157 dermatologists in a head-to-head dermoscopic melanoma image classification task*. European Journal of Cancer, v. 113, p. 47-54, 2019.

- [24] Rajpurkar, P.; Irvin, J.; Zhu, K.; Yang, B.; Mehta, H.; Duan, T.; Ding, D.; et al. *CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning*. arXiv preprint arXiv:1711.05225, 2017.
- [25] McKinney, S. M.; Sieniek, M.; Godbole, V.; Godwin, J.; Antropova, N.; Ashraffian, H.; Back, T.; et al. *International evaluation of an AI system for breast cancer screening*. Nature, v. 577, n. 7788, p. 89-94, 2020.
- [26] World Health Organization. *Digital health strategy 2020-2025*. Geneva: WHO, 2021. Disponível em: <https://www.who.int/docs/default-source/documents/g54dhdaa2a9f352b0445bafbc79ca799dce4d.pdf>. Acesso em: 20 jul. 2024.
- [27] Garnelo, L.; Lima, J. G.; Rocha, E. S. C.; Herkrath, F. J. *Acesso e cobertura da Atenção Primária à Saúde para populações rurais e urbanas na região norte do Brasil*. Saúde em Debate, v. 42, n. 1, p. 81-99, 2018.
- [28] Viana, A. L. d'Ávila; Machado, C. V.; Lima, L. D.; Baptista, T. W. F.; Mendonça, M. H. M.; Heimann, L. S. *Regionalização e redes de saúde*. Ciência & Saúde Coletiva, v. 23, n. 6, p. 1791-1798, 2018.